



Ładowanie Danych

Praktyczny przewodnik po zasilaniu baz grafowych.

dr Zbigniew Galar



Złota zasada: Start Small




Przetestuj architekturę i mapowania na małym wycinku danych przed pełnym importem. Szybki test poprawności modelu oszczędzi Ci godzin frustracji.

Trzy drogi do zasilenia grafu

	Neo4j Data Importer	LOAD CSV	neo4j-admin import
Status Bazy	Online (działa na żywo)	Online (działa na żywo)	Offline (wyłączona)
Podejście	Wizualne (Drag & Drop)	Skryptowe (Cypher)	Niskopoziomowe (CLI)
Szybkość	Umiarkowana	Wysoka (Batching)	Ekstremalna (~1 mln/s)
Idealne dla	Początkujących i szybkiego prototypowania.	Elastycznego importu ze źródeł sieciowych (S3, HTTP).	Masowego, inicjalnego ładowania danych od zera.

Neo4j Data Importer:

Mapowanie bez kodowania



1 Wymaga jedynie **płaskich plików CSV**.

2 Rysujesz model domenowy jako **wizualny graf**.

3 Działa bezpośrednio na **aktywnej, żywej bazie**.


Anatomia Identyfikatorów

Świat CSV

people.csv

:ID(Person)	name
23	Rosa

Świat Grafu



Wewnętrzne ID: 23

Kolumny identyfikatorów (np. :ID(Person), :START_ID, :END_ID) to technologiczny klej. Łączą odizolowane pliki w zintegrowaną sieć. Po imporcie można je często usunąć z docelowego modelu.

Co dzieje się pod maską?

Automatyczny Cypher

```
UNWIND $relRecords AS relRecord
```

Rozwija wejściową listę rekordów do pojedynczych wierszy.


```
MATCH (source: `Person` { `:ID(Person)`: relRecord.`START_ID(Person)` })  
MATCH (target: `Place` { `:ID(Place)`: relRecord.`END_ID(Place)` })
```

Znajduje istniejące już węzły startowe i końcowe w bazie.

```
MERGE (source)-[r: `LIVES_IN`]->(target)  
SET r.`since` = toInteger(relRecord.`since`);
```

MERGE tworzy relację tylko, jeśli jeszcze nie istnieje (zapobiega duplikatom). SET bezpiecznie przypisuje właściwości.

LOAD CSV: Wszechstronny skryptowy rurociąg



Import w tle, bez zatrzymywania działającej bazy.

Bezpośredni odczyt z publicznych adresów URL.

Natywna, automatyczna obsługa skompresowanych archiwów.

Pełna moc języka Cypher – filtrowanie i transformacja w locie.

Anatomia zapytania LOAD CSV

places.csv

city	country
Berlin	Germany

```
LOAD CSV WITH HEADERS FROM 'places.csv' AS line  
MERGE (:Place {country: line.country, city: line.city})
```

1

Zmusza parser do odczytania pierwszej wiersza jako nazw zmiennych.

2

Przypisuje każdy iterowany wiersz CSV do zmiennej obiektowej.

3

Pułapka Nieregularnych Danych

people.csv

name,gender,age -> Fred,,,

Brakujące dane (Null)

Błędna droga

MERGE (p:Person {name: line.name,
age: line.age})


BŁĄD! Operacja MERGE odrzuci całą transakcję, jeśli napotka wartość null w jakiegokolwiek definiowanej właściwości.

Dobra praktyka

MERGE (p:Person {name: line.name})
SET p.age = line.age

SUKCES! MERGE opiera się wyłącznie na pewnym kluczu głównym (name). SET ignoruje operację, jeśli pole wejściowe jest puste.

Zarządzanie Pamięcią: Import Wsadowy (Batching)



```
CALL {  
  WITH line  
  MERGE (p:Person {name: line.name})  
  SET p.age = line.age  
} IN TRANSACTIONS OF 10000 ROWS
```

Zapobiega błędowi OutOfMemory. Dzieli potężny zbiór na lekkie porcje, zachowując płynność i responsywność całej bazy grafowej.

Wąskie gardła: Profilowanie przed produkcją




Iloczyn Kartezjański (Cartesian Products)

Niekontrolowane mnożenie zbiorów danych.
Wymaga precyzyjnego filtrowania przed uruchomieniem.




Operatory Eager (Eager Operators)

Dławiki wydajnościowe, które zamiast przetwarzać dane strumieniowo, ładują całość bezpośrednio do pamięci RAM.



Złota zasada inżynierii: Zawsze używaj prefiksu EXPLAIN lub PROFILE na małej próbce danych przed puszczeniem skryptu na produkcję.

neo4j-admin import: Ciężki Sprzęt



Przepustowość: ~1,000,000 rekordów/s

Przeznaczenie

Inicjalne ładowanie (bootstrapping) lub masowe budowanie ogromnych baz od zera.

Architektura

Omija narzut transakcyjny i zapisuje bezpośrednio na dysk (optymalizacja dla SSD/SAN).

Wymagania



Baza **MUSI** być **całkowicie wyłączona** podczas procesu importu.

Źródło Danych

Wyłącznie **lokalny system plików** (brak wsparcia dla sieciowych strumieni S3/HTTP).

Architektura Plików: Oddzielenie Schematu od Danych

ZŁO



friends.csv (50 GB)

Structural

Nieemożliwy do otwarcia w zwykłym edytorze tekstu. Błąd w nagłówku wymusza przetwarzanie całego pliku.

DOBRO



import/



friends_header.csv



friends_data_part1.csv



friends_data_part2.csv

:START_ID(Person), :END_ID(Person)

Tylko lekka sygnatura schematu. Zmiany trwają ułamek sekundy.

23,42
42,55

Surowe, podzielone paczki danych bez nagłówków.

Egzekucja CLI: Spinanie węzłów i relacji

```
bin/neo4j-admin import "\n"  
--nodes=Person=import/people.csv \\n"  
--relationships=FRIEND=import/friends_header.csv,import/friends1.csv \\n"  
--nodes=Place=import/places_header.csv,import/places1.csv
```

Łączy rozbite pliki w jeden logiczny zbiór.

UWAGA KRYTYCZNA: Narzędzie importu potrafi zużywać gigantyczne ilości pamięci RAM i operacja może trwać godzinami. Proces nie wspiera wznowiania (*not resumtable*). Przypadkowe naciśnięcie **Ctrl+C** oznacza konieczność zaczęcia całego importu od absolutnego zera.

Wybierz Swoje Narzędzie (The Tool Selector)

