


Wzbogacanie o Data Science

Wykorzystanie algorytmów
grafowych do odkrywania
ukrytej wiedzy.


dr Zbigniew Galar

16:9




Od surowych powiązań do strategicznej wiedzy

Dane




- Ludzka inspekcja zawodzi przy dużej skali.

Wiedza




- Algorytmy aktywnie przeliczają topologię grafu.
- Automatyczne odkrywanie wąskich gardeł, liderów opinii i ukrytych społeczności.

Trzy Filary Graph Data Science




Statystyczne

Kontekst i metryki.
Dystrybucja węzłów,
relacji i typów w grafie.



Analityczne


Ujawnianie wzorców.
Identyfikacja ukrytych
struktur w topologii grafu.




Machine Learning

Trenowanie modeli.
Wykorzystanie wyników
algorytmów grafowych jako
cech zasilających modele
uczenia maszynowego.

Matryca Algorytmów Analitycznych

Kategoria	Motyw	Zastosowanie
Propagacja		Rozprzestrzenianie sygnałów, chorób, analizy łańcucha dostaw.
Wpływ i Centralność		Wąskie gardła, mosty informacyjne, influencerzy.
Wykrywanie Społeczności		Grupy oszustów, systemy rekomendacji, bańki informacyjne.
Podobieństwo		Rekomendacje produktów dla podobnych klientów.
Przewidywanie Linków		Sugestie znajomości, predykcja brakujących relacji.


Architektura GDS: Projekcja Grafu




Zamiast obciążać dysk operacjami matematycznymi, **GDS rzutuje** (projekcja) **skompresowaną topologię** bezpośrednio do **pamięci RAM**.

Rozwiązania **rozproszone** (typu Hadoop) są **nieefektywne** dla grafów przez opóźnienia sieciowe. Architektura **Scale-up** gwarantuje korzyści z **lokalności pamięci** (superszybkie śledzenie wskaźników węzłów).

Cykl Operacyjny GDS



Środowisko Eksperymentalne




Podejście Data Scientist:

Praca w 100% z idiomatycznym kodem Python (obiekty, DataFrames).

Brak inżynierii niskopoziomowej:

Biblioteka graphdatascience abstrahuje złożoność bazy danych. Brak konieczności ręcznego zarządzania sterownikami czy sesjami bazy danych. Szybka iteracja i testowanie hipotez.

Studium Przypadku: Sieć Kolejowa UK



Zbiór danych: Stacje kolejowe (Węzły) i Tory z dystansem (Relacje).

Hipoteza Intuicyjna:
Birmingham New Street to najruchliwsza stacja poza Londynem (47 mln pasażerów).

Ludzka intuicja podpowiada, że to absolutnie najważniejszy, krytyczny węzeł całej sieci (najwyższa centralność).

Paradoks Centralności


Oczekiwania



~254 000

Birmingham New Street

Matematyczna Rzeczywistość




~1 960 000

Tamworth

Dlaczego? Efekt Sieciowy


Choć Tamworth ma tylko 1,2 mln pasażerów, jest matematycznie kluczowym mostem łączącym rozległe trasy. Awaria infrastruktury w Tamworth spowoduje kaskadowy paraliż sieci, który fizycznie zablokuje ruch w Birmingham. Algorytmy widzą całą strukturę, a nie tylko ruch lokalny.

Przejsście na Produkcję: Izolacja Fizyczna




Spójność Danych: Bariera Przyczynowa

Architektura HTAP: Jedna technologia obsługuje transakcje i analitykę. Zero złożonych procesów ETL.




Wzbogacanie Grafu Wiedzy



Cechy Węzłów: Wyniki algorytmów stają się trwałymi atrybutami grafu. Te wyliczone parametry sterują narzędziami wizualnymi oraz stanowią zaawansowane cechy wejściowe dla algorytmów Uczenia Maszynowego.

Podsumowanie




1. Odkrywanie Ukrytych Struktur

Algorytmy ujawniają nieoczywiste, mierzalne wzorce (np. paradoks Tamworth), przekraczając granice ludzkiej intuicji.



2. Płynne Eksperymentowanie

Zintegrowane środowisko Python pozwala na szybkie iteracje i testowanie hipotez bez barier technologicznych.



3. Z Laboratorium na Produkcję

Unikalna architektura grafowa natywnie wspiera analitykę (HTAP), eliminując potrzebę tworzenia skomplikowanych rurociągów ETL.