


Grafy Wiedzy

Rozwiązywanie Problemu Tożsamości


Budowa 360-stopniowego widoku danych
za pomocą analizy topologicznej

Autor: dr Zbigniew Galar



Paradoks Tożsamości

Jak system bankowy ma rozpoznać, że **Jane Coleman** i **Jane Downe** to ta sama osoba, gdy brakuje spójnych identyfikatorów?



Entity Resolution (Rozwiązywanie Tożsamości) i **Master Data Management** (Zarządzanie Danymi Master). Bez rozwiązania tego problemu analiza danych jest bezwartościowa.

Skąd bierze się chaos w danych?

Integracja Danych (Silozy)



Różne systemy (CRM, Sprzedaż, Marketing) przechowują warianty tych samych danych w niezależnych formatach.



Aktywność Anonimowa




Użytkownicy bez uwierzytelnienia. Zostawiają jedynie cyfrowe ślady: ciasteczka, kliknięcia, adresy IP o krótkiej żywotności.



Oszustwa i Manipulacje




Celowe tworzenie duplikatów (np. modyfikacja wieku w celu uzyskania lepszej wyceny ubezpieczenia, nadużywanie darmowych okresów próbnych).




Wynik: Rozproszone, niepowiązane dane utrudniające analitykę.

Metodologia Grafowa: Od Chaosu do Złotego Rekordu


Krok 1: Przygotowanie Danych



Krok 2: Dopasowywanie Encji (Silnik Reguł)



Krok 3: Kuracja Encji Nadrzędnych



Krok 1: Przygotowanie Danych

Harmonizacja i czyszczenie surowych plików.

Krok 2: Dopasowywanie Encji (Silnik Reguł)

Aplikacja logiki grafowej do identyfikacji i łączenia relacji.

Krok 3: Kuracja Encji Nadrzędnych


Synteza powiązanych rekordów w jeden trwały, weryfikowalny Złoty Rekord.

Matryca Typologii Identyfikatorów

Typ Identyfikatora	Przykłady	Akcja Grafowa	Tworzona Relacja
Silne Identyfikatory (Strong Identifiers)	• PESEL, • Numer Paszportu, • SSN	Dokładne dopasowanie (Exact Match)	Tworzy twarde powiązanie: SAME_AS 
Słabe Identyfikatory (Weak Identifiers)	• Imię, • Nazwisko, • E-mail	Dopasowanie rozmyte (Fuzzy matching)	Tworzy probabilistyczne powiązanie: SIMILAR 
Cechy Nieidentyfikujące (Non-Identifying)	• Rok urodzenia, • Wiek, • Płeć	Weryfikacja kontekstowa	Modyfikator wagi (Boost/Dampen) dla relacji SIMILAR 


Krok 1: Harmonizacja i standaryzacja

Zasada Najmniejszego Wspólnego Mianownika:
Zanim połączymy punkty, musimy mówić tym samym językiem.
Różne formaty dat urodzenia (wiek, pełna data) są normalizowane do jednej zmiennej `m_yob`. Imiona są redukowane do formatu kanonicznego `m_fullname`.



Klucze Blokujące (Blocking Keys): Opcjonalna technika redukująca przestrzeń poszukiwań. Zamiast porównywać każdy rekord z każdym, porównujemy tylko rekordy z tym samym kluczem (np. kodem pocztowym).

Krok 2: Fundamenty Tożsamości




Proces

Jeśli silny identyfikator (np. numer paszportu) pasuje idealnie, algorytm natychmiast tworzy bezwzględną, symetryczną relację.

Logika Cypher

Skrypt sprawdza bazy i omija podwójne porównania, tworząc solidny szkielet początkowej konstelacji danych.

Krok Krok 3: Analiza Słabych Dowodów





Proces

Brak silnych identyfikatorów zmusza do szukania poszlak. Wykorzystujemy algorytmy podobieństwa ciągów znaków dla znormalizowanych imion i nazwisk.

Skoring


Relacja SIMILAR powstaje tylko wtedy, gdy dystans Jaro-Winklera jest mniejszy niż ustalony próg. Waga relacji staje się wynikiem prawdopodobieństwa tożsamości.

Krok 4 & 5: Filtr Fałszywie Dodatnich



Autokorekta Grafu: Słabe podobieństwa (imiona) są natychmiast **odrzucone**, jeśli twarde dowody (SSN) są ze sobą sprzeczne. To eliminuje fałszywych bliźniaków. Dodatkowo, cechy nieidentyfikujące (np. rok urodzenia) kalibrują wynik – działając jako modyfikator wagi (boost/dampen) o +/- 10%.

Algorytm WCC: Odkrywanie Konstelacji




Mapowanie Topologii

Po nałożeniu reguł dopasowania, graf jest pełen powiązań. Zastosowanie algorytmu Weakly Connected Connected Components (WCC) pozwala na analizę nieskierowanych grafów.

Izolacja Subgrafów

Algorytm WCC przeszukuje całą przestrzeń danych, identyfikując odizolowane subgrafy (komponenty). Każdy taki połączony zbiór węzłów staje się unikalną jednostką – pojedynczą tożsamością.

Synteza: Narodziny Złotego Rekordu



Cel Ostateczny


Konwersja komponentów WCC w jedną trwale zapisaną encję nadrzędną. Chaos staje się strukturą.

Widok 360 Stopni

Złoty Rekord agreguje wszystkie poprawne atrybuty (ostateczne imię, połączone numery identyfikacyjne), zachowując pełną identyfikowalność (HAS_REFERENCE) z oryginalnymi systemami źródłowymi.

Wyzwanie Zaawansowane: Dane Nieustrukturyzowane

Problem Brakujących Identyfikatorów: Co się dzieje, gdy nie mamy ani PESEL-u, ani numerów seryjnych? Klasyczne dopasowanie upada w obliczu swobodnego tekstu.



Rekordy składają się wyłącznie z opisów tekstowych. Jak grafy radzą sobie z analizą lingwistyczną?


Mosty Pojęciowe: Grafy Dwudzielne i Tokenizacja

Modelowanie Tekstu:

Ciągi znaków są dzielone na pojedyncze słowa (tokeny), które stają się samodzielnymi węzłami w grafie dwudzielnym.

Algorytm Podobieństwa Węzłów:

Wykorzystanie metryki Jaccarda. Dwa węzły produktów są uznawane za podobne, jeśli dzielą gęstą sieć tych samych sąsiadów (wspólne słow.). Tekst staje się mierzalną mierzalną topologią.



Skala Enterprise: Studium Przypadku Meredith Corporation

Zasób Danych

4,4 TB

Pojemność bazy danych z 20 miesięcy anonimowych ciasteczek.

Architektura Grafu

30 Miliardów

Liczba węzłów przetwarzana przez algorytm WCC.

Konsolidacja Profili

350M -> 163M

Zaszumione profile zredukowane do wysoce dokładnych Złotych Rekordów.


Czas Śledzenia (Wydłużenie)

14 -> 241 dni

Znaczny wzrost czasu ciągłego śledzenia pojedynczego klienta.

Zastosowanie: Analiza danych z ciasteczek z wykorzystaniem algorytmu WCC.
Rezultat to hiper-dokładny obraz klienta.

Topologiczne Podejście do Prawdy



Podsumowanie: Grafy wiedzy pozwalają na przekształcenie rozproszonych, słabych identyfikatorów w potężne, wiarygodne dane nadrzędne. Rozwiązywanie problemu tożsamości to nie tylko kwestia dopasowywania wierszy. To budowanie dynamicznej konstelacji danych, w której relacje i topologia grafu same weryfikują prawdę o kliencie.