


Wyszukiwanie semantyczne i podobieństwo

Budowa grafów wiedzy w celu przejścia od ciągów znaków do rzeczy

dr Zbigniew Galar



Złożoność języka naturalnego pokonuje proste indeksy



Tradycyjne wyszukiwarki dopasowują tylko to, co wpiszesz. Ignorują liczbę liczbę mnogą, synonimy, skróty i kontekst.

Przeszukując słowa, tracisz znaczenie.



Proste algorytmy, jak zliczanie słów czy TF-IDF, nie potrafią zrozumieć relacji ani ukrytych intencji użytkownika.

Rozwiązanie: Rzeczy, nie ciągi znaków (Things, not Strings)




Ciągi znaków (Wyszukiwanie Słowne)



Rzeczy (Wyszukiwanie Semantyczne)


Aby zautomatyzować analizę dokumentów, musimy przenieść przetwarzanie na wyższy poziom abstrakcji. Zamiast ciągów znaków, algorytmy muszą szukać konkretnych bytów i ich relacji.

Krok 1: Ekstrakcja Encji za pomocą NLP (NER)




Algorytm rozpoznawania encji nazwanych (NER) bezbłędnie identyfikuje obiekty ukryte w tekście, przypisując im typ (np. organizacja, osoba) oraz istotność (saliency).

Konstrukcja podstawowego grafu wiedzy



Powiązanie dokumentów z encjami staje się jawne i ważne. Wynikiem jest architektura gotowa do zapytań o powiązania i wielowymiarowej analizy tematów.


Analiza Powiązań: Odkrywanie podobieństwa dokumentów



Rekomendacje oparte na treści. Artykuły są ze sobą powiązane nie przez historię kliknięć użytkowników, ale poprzez obiektywne fakty, o których traktują.

Obliczanie wagi podobieństwa: Od wielu wymiarów do jednej relacji

Krok 1: Bipartite Graph




Bipartite graph: articles and entities

Krok 2

Suma (waga A × waga B)

Matematyczne spłaszczenie
złożonej sieci

Krok 3: Monopartite Graph




Monopartite graph: similar articles

Zamiast obliczać dystans przy każdym zapytaniu, relacje podobieństwa są materializowane bezpośrednio w grafie, co umożliwia błyskawiczne rekomendacje.


Nawigowanie bez mapy: Problem Zimnego Startu



Scenariusz A: Nowy Użytkownik




Scenariusz B: Aktywny Użytkownik




Graf potrafi elastycznie odpowiadać na sytuację: od globalnych trendów czasowych po wysoce spersonalizowane algorytmy podobieństwa oparte na historii czytania.

Przeszkoda: Niejednoznaczność i brak domyślnej hierarchii




Sama ekstrakcja podmiotów (NER) to za mało. Algorytm nie potrafi rozwiązać problemu polisemii (synonimów i skrótów), a co najważniejsze – nie zna domyślnej struktury świata i relacji między pojęciami.

Krok 2: Ontologie i Słowniki jako Zasady Porządkujące



Ontologie (jak MeSH, Disease Ontology czy Wikidata) dostarczają brakujących reguł (schematów pojęciowych), definiując obiekty domeny oraz to, w jaki sposób są ze sobą trwale połączone.


Precyzyjne ujednoznacznianie (Entity Disambiguation)



Mapując surową encję z tekstu bezpośrednio na unikalny identyfikator w ontologii (za pomocą np. linków Wikipedii dostarczanych przez API), graf zyskuje absolutną pewność co do znaczenia danego słowa.

Przełom: Wyszukiwanie Zrozumienia (Wiedza Niejawna)

Wyszukiwarka znajduje artykuły polegając na hierarchii pojęć (drzewie ontologii), a nie na jawnym wystąpieniu tekstu. To jest esencja wdrożenia zasady: rzeczy, nie ciągi znaków.




Ewolucja Wyszukiwania: Od Słów do Znaczeń

Parametr	Wyszukiwanie Słowne (Keyword)	Ekstrakcja Encji (NER Graph)	Graf Semantyczny (Semantic Graph)
Cel Wyszukiwania	Ciągi znaków ✗	Izolowane Byty ✗	Powiązane Koncepcje (Zwycięzca) ✓
Radzenie sobie z synonimami	Ignoruje ✗	Częściowo ✗ (zależne od modelu)	Całkowicie ujednolicono ✓ (Zwycięzca)
Świadomość Hierarchii	Brak ✗	Brak ✗	Pełna dziedziczność ✓ (np. Walia to część UK) (Zwycięzca)
Narzędzia / Architektura	ElasticSearch / Indeksy 🔍 🗄️	Hugging Face + 🧠 👉 Neo4j 🌐	GCP NLP + Wikidata + 🌐 Neo4j 🗄️

Studium Przypadku: Baza Wiedzy NASA (LLIS)

Przed - Status Quo



- Rozproszone silosy danych
- 20 milionów nieustrukturyzowanych dokumentów
- Wyszukanie generowało tysiące nieskorelowanych i nieprzydatnych wyników

Po - Graf Semantyczny



- Wdrożenie grafu połączonego encjami i ontologią
- Zrozumienie powiązań tematycznych i przewidywanie błędów
- Ocalenie kluczowej wiedzy inżynierskiej zbieranej od lat 60.

“Wynik: “Zaoszczędziliśmy co najmniej rok pracy i ponad 2 miliony dolarów na badaniach przy planowaniu misji na Marsa.”

”

Architektura Wyszukiwania Semantycznego w Pigułce

Surowe Dokumenty



Ekstrakcja NLP



Ujednolicanie GCP



Łączenie Ontologii Wikidata



Graf Semantyczny Neo4j



1. Zrozumienie, nie indeksowanie

Inteligentny system musi opierać się na encjach i regułach organizujących świat wiedzy.



2. Odkrywanie wiedzy niejawnej

Grafy ujawniają podobieństwa oparte na ontologicznych powiązaniach ukrytych w treści.



3. Gotowość na przyszłość

Budowa grafów wiedzy na nieustrukturyzowanych danych to obowiązkowa ewolucja przygotowująca przedsiębiorstwo na erę inteligentnego AI.