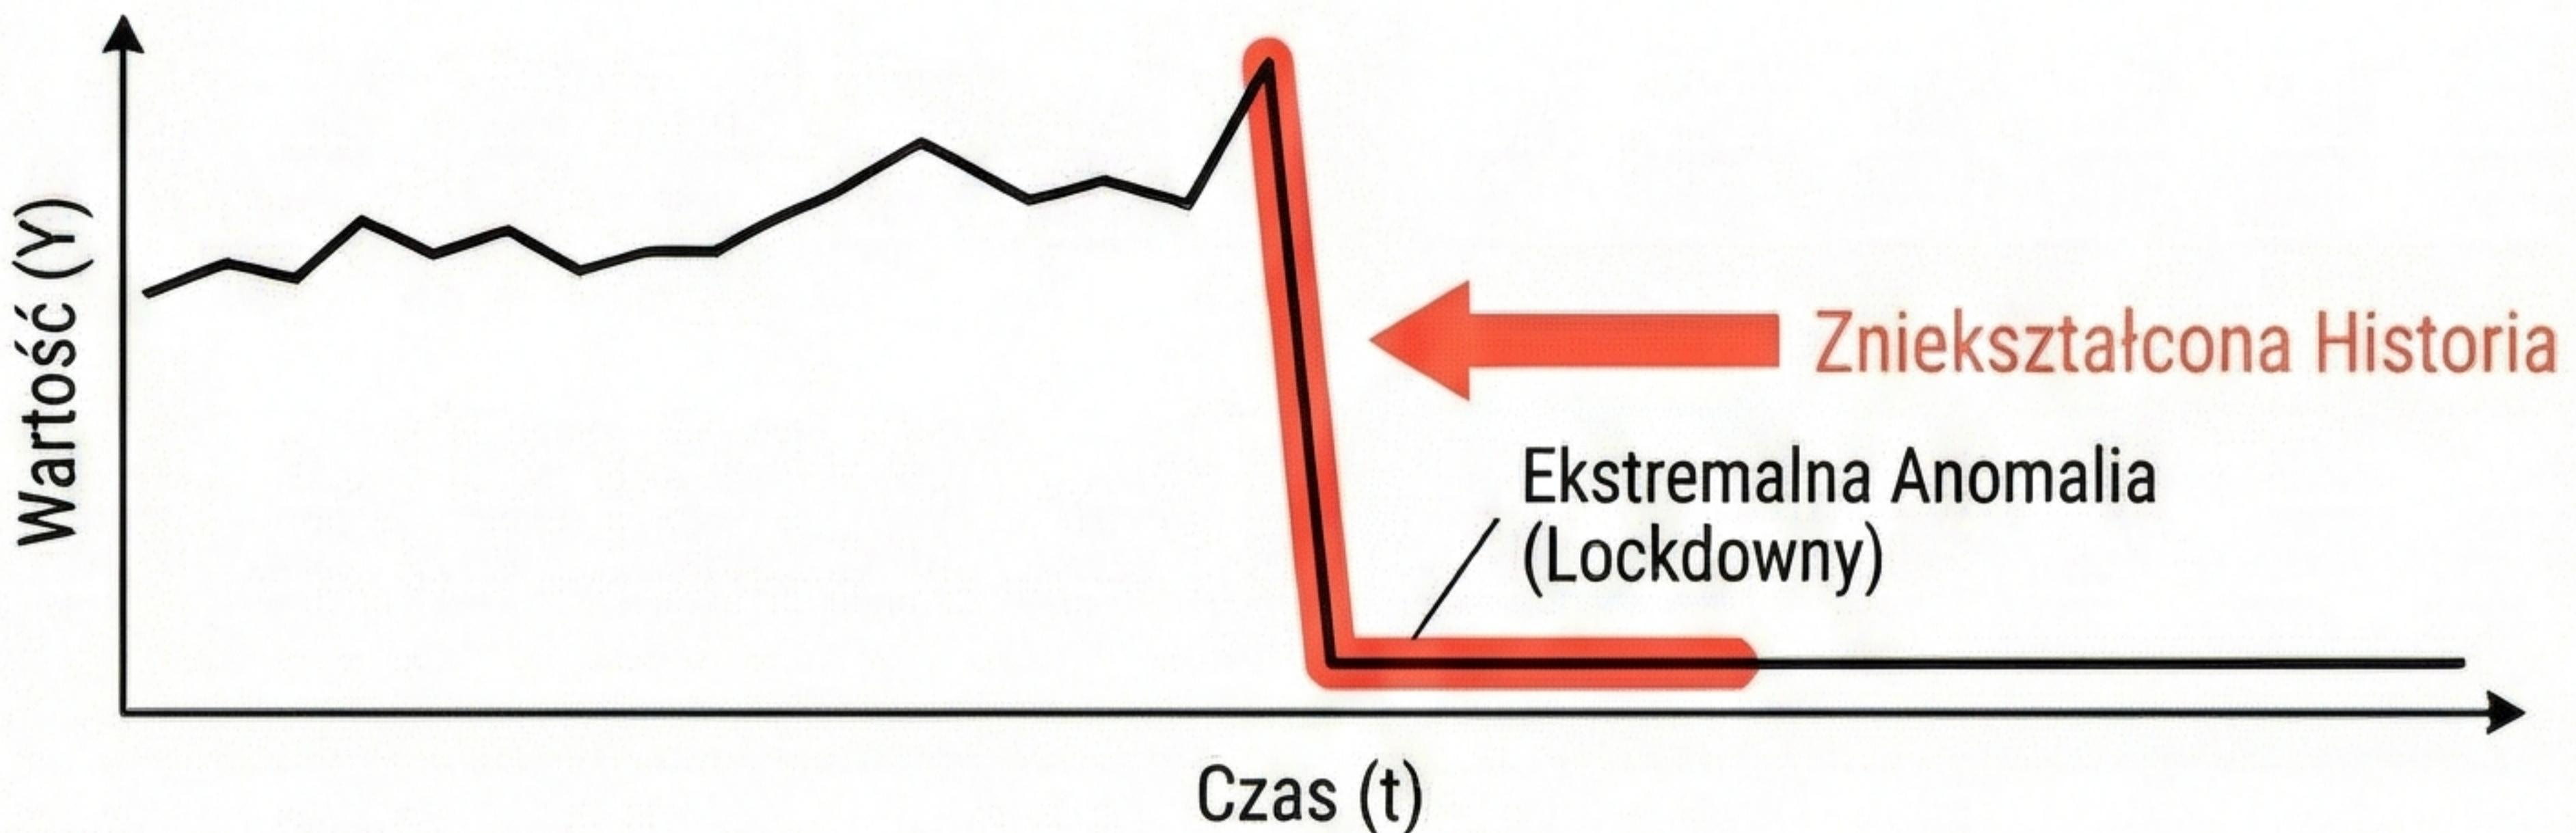


29 PL Predictive Statistics Input History	
correction in time series forecasting	2
30 PL Predictive Statistics wMAPE in Power	
BI	3

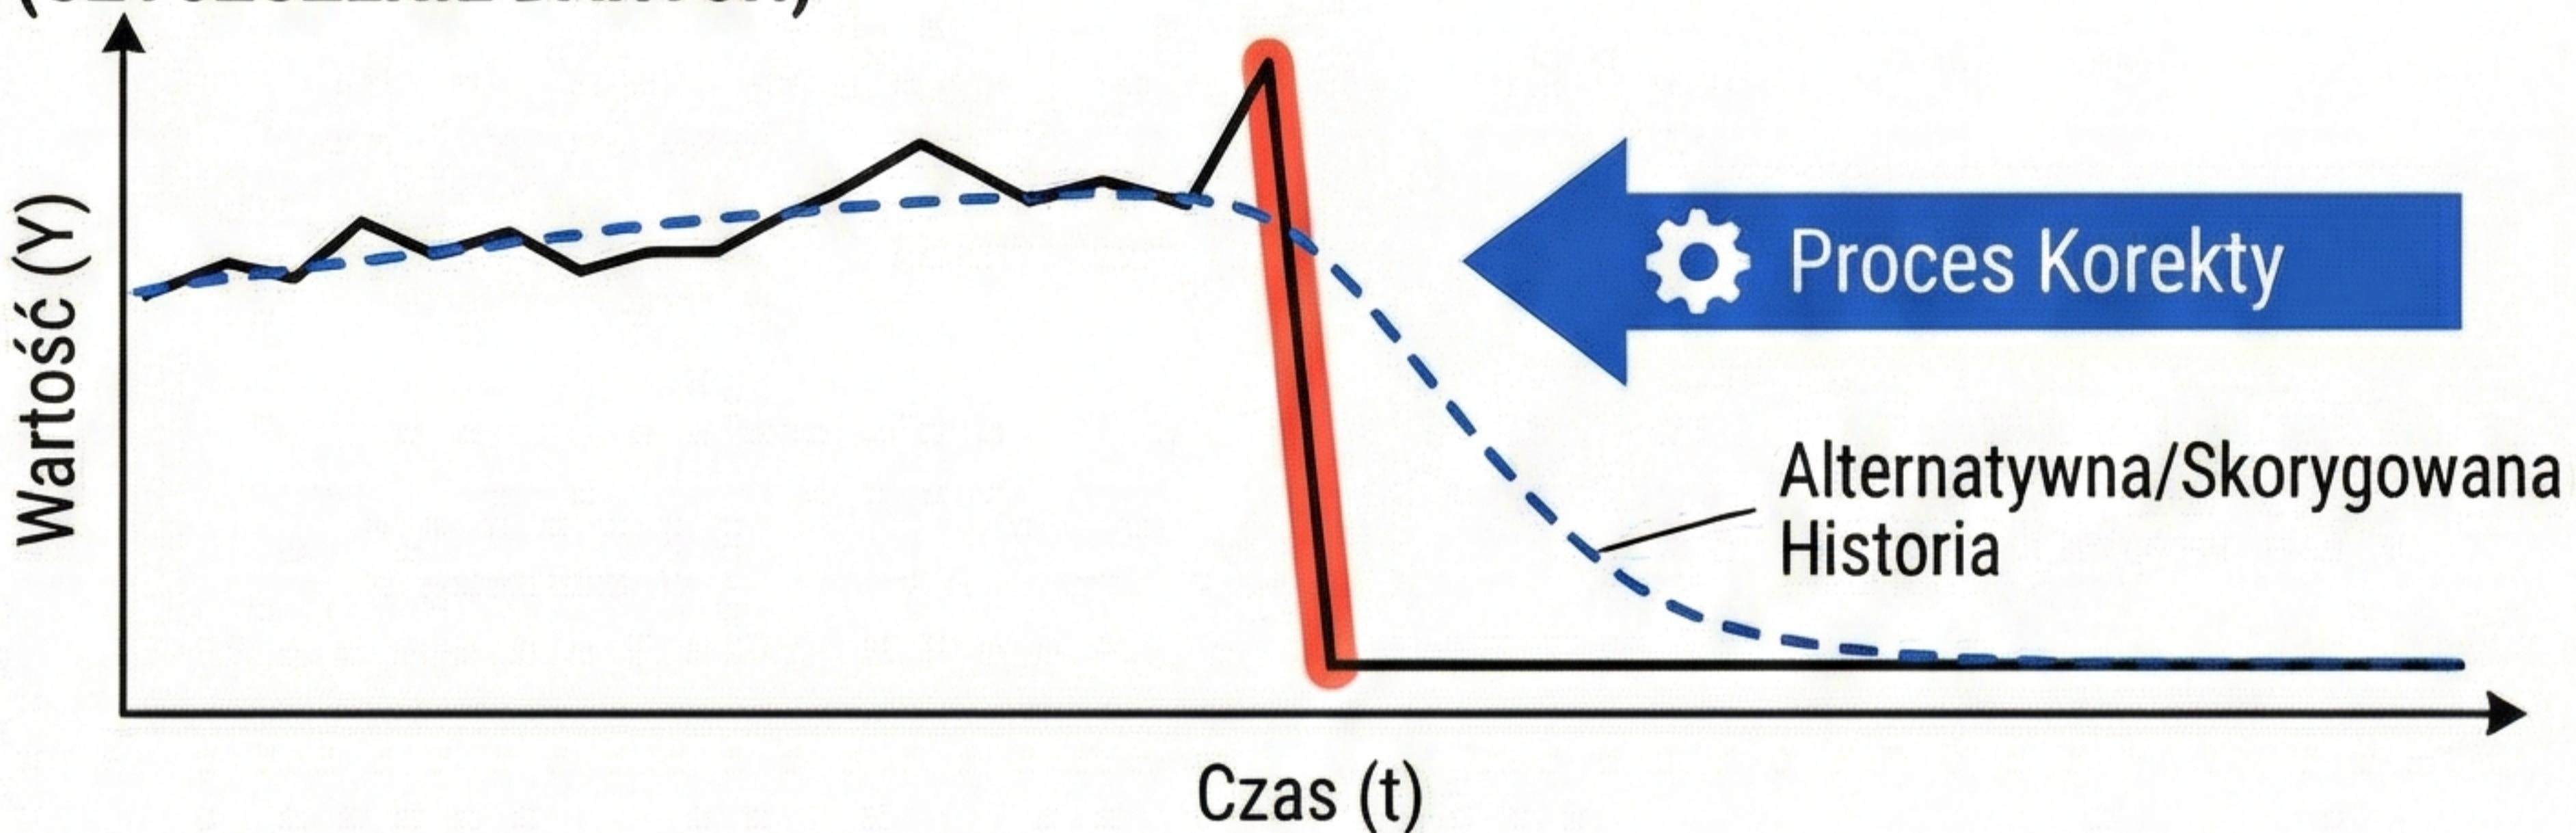
KOREKTA HISTORII DANYCH WEJŚCIOWYCH W PROGNOZOWANIU SZEREGÓW CZASOWYCH

PROBLEM: ZDARZENIE CZARNEGO ŁABĘDZIA (LOCKDOWNY PANDEMICZNE)



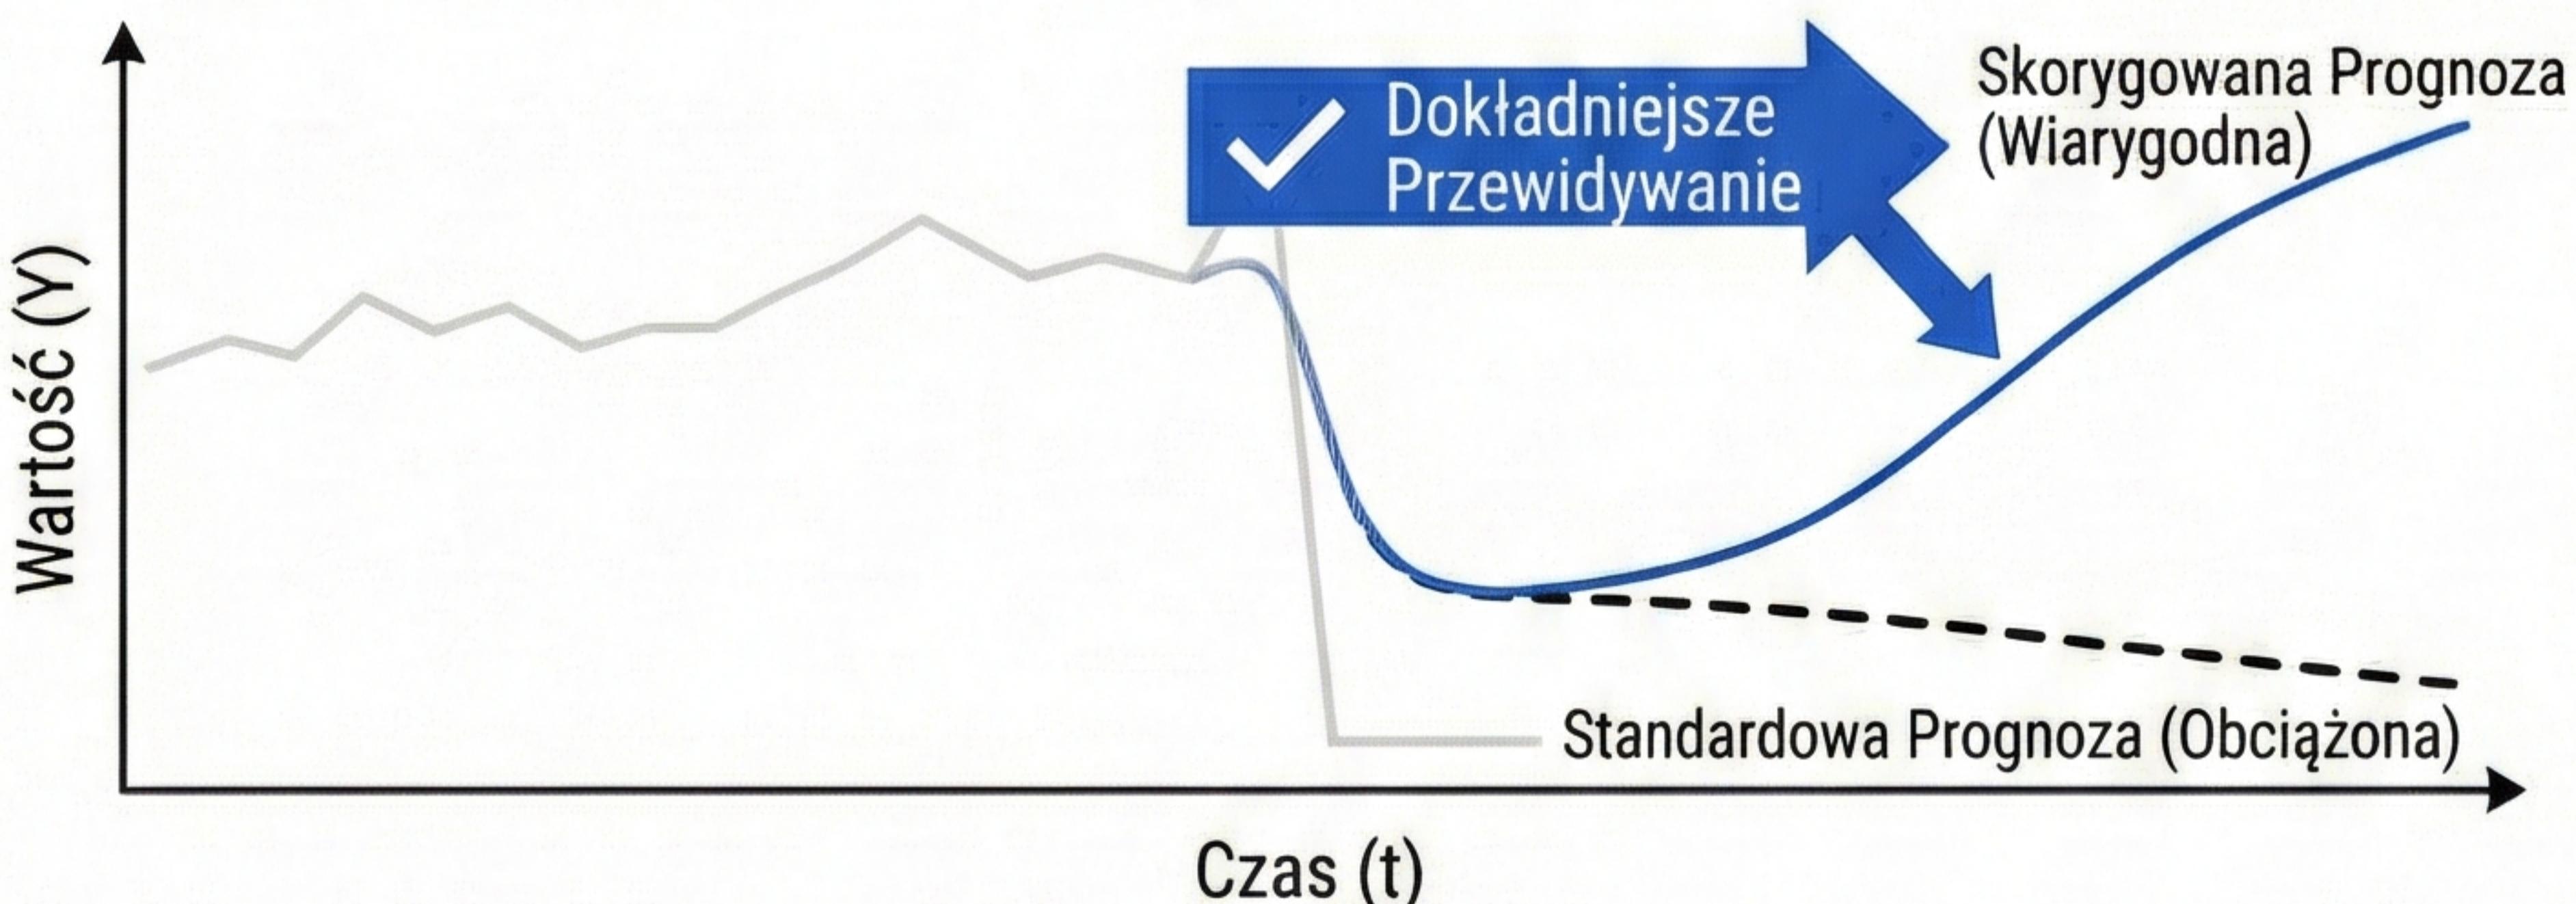
Dane historyczne są zniekształcone przez rzadkie, ekstremalne zdarzenia, co prowadzi do niedokładnych przyszłych prognoz.

ROZWIĄZANIE: KOREKTA HISTORII DANYCH WEJŚCIOWYCH (CZYSZCZENIE DANYCH)



Anomalne punkty danych są identyfikowane i zastępowane szacowanymi wartościami "normalnymi" (np. przy użyciu interpolacji lub podobnych okresów z przeszłości).

WYNIK: ULEPSZONA PROGNOZA (PO KOREKCIE)



Modele prognostyczne trenowane na skorygowanej historii generują bardziej wiarygodne przyszłe przewidywania, ignorując obciążenie ekstremalnym zdarzeniem.

MIARA DOKŁADNOŚCI PROGNOZY: 1-wMAPE (WAŻONY ŚREDNI BEZWZGLĘDNY PROCENTOWY BŁĄD)

1. DEFINICJA POJĘCIA

wMAPE (Ważony MAPE)

Całkowity Ważony Procentowy Błąd



= wMAPE

Całkowita Waga (np. COGS)

Mierzy ważoną średnią bezwzględnych błędów procentowych, nadając priorytet elementom w oparciu o ich wagę (znaczenie).

MIARA DOKŁADNOŚCI (1-wMAPE)



Dopełnienie wMAPE. Reprezentuje proporcję prognozy, która jest dokładna (0-1 lub 0-100%).

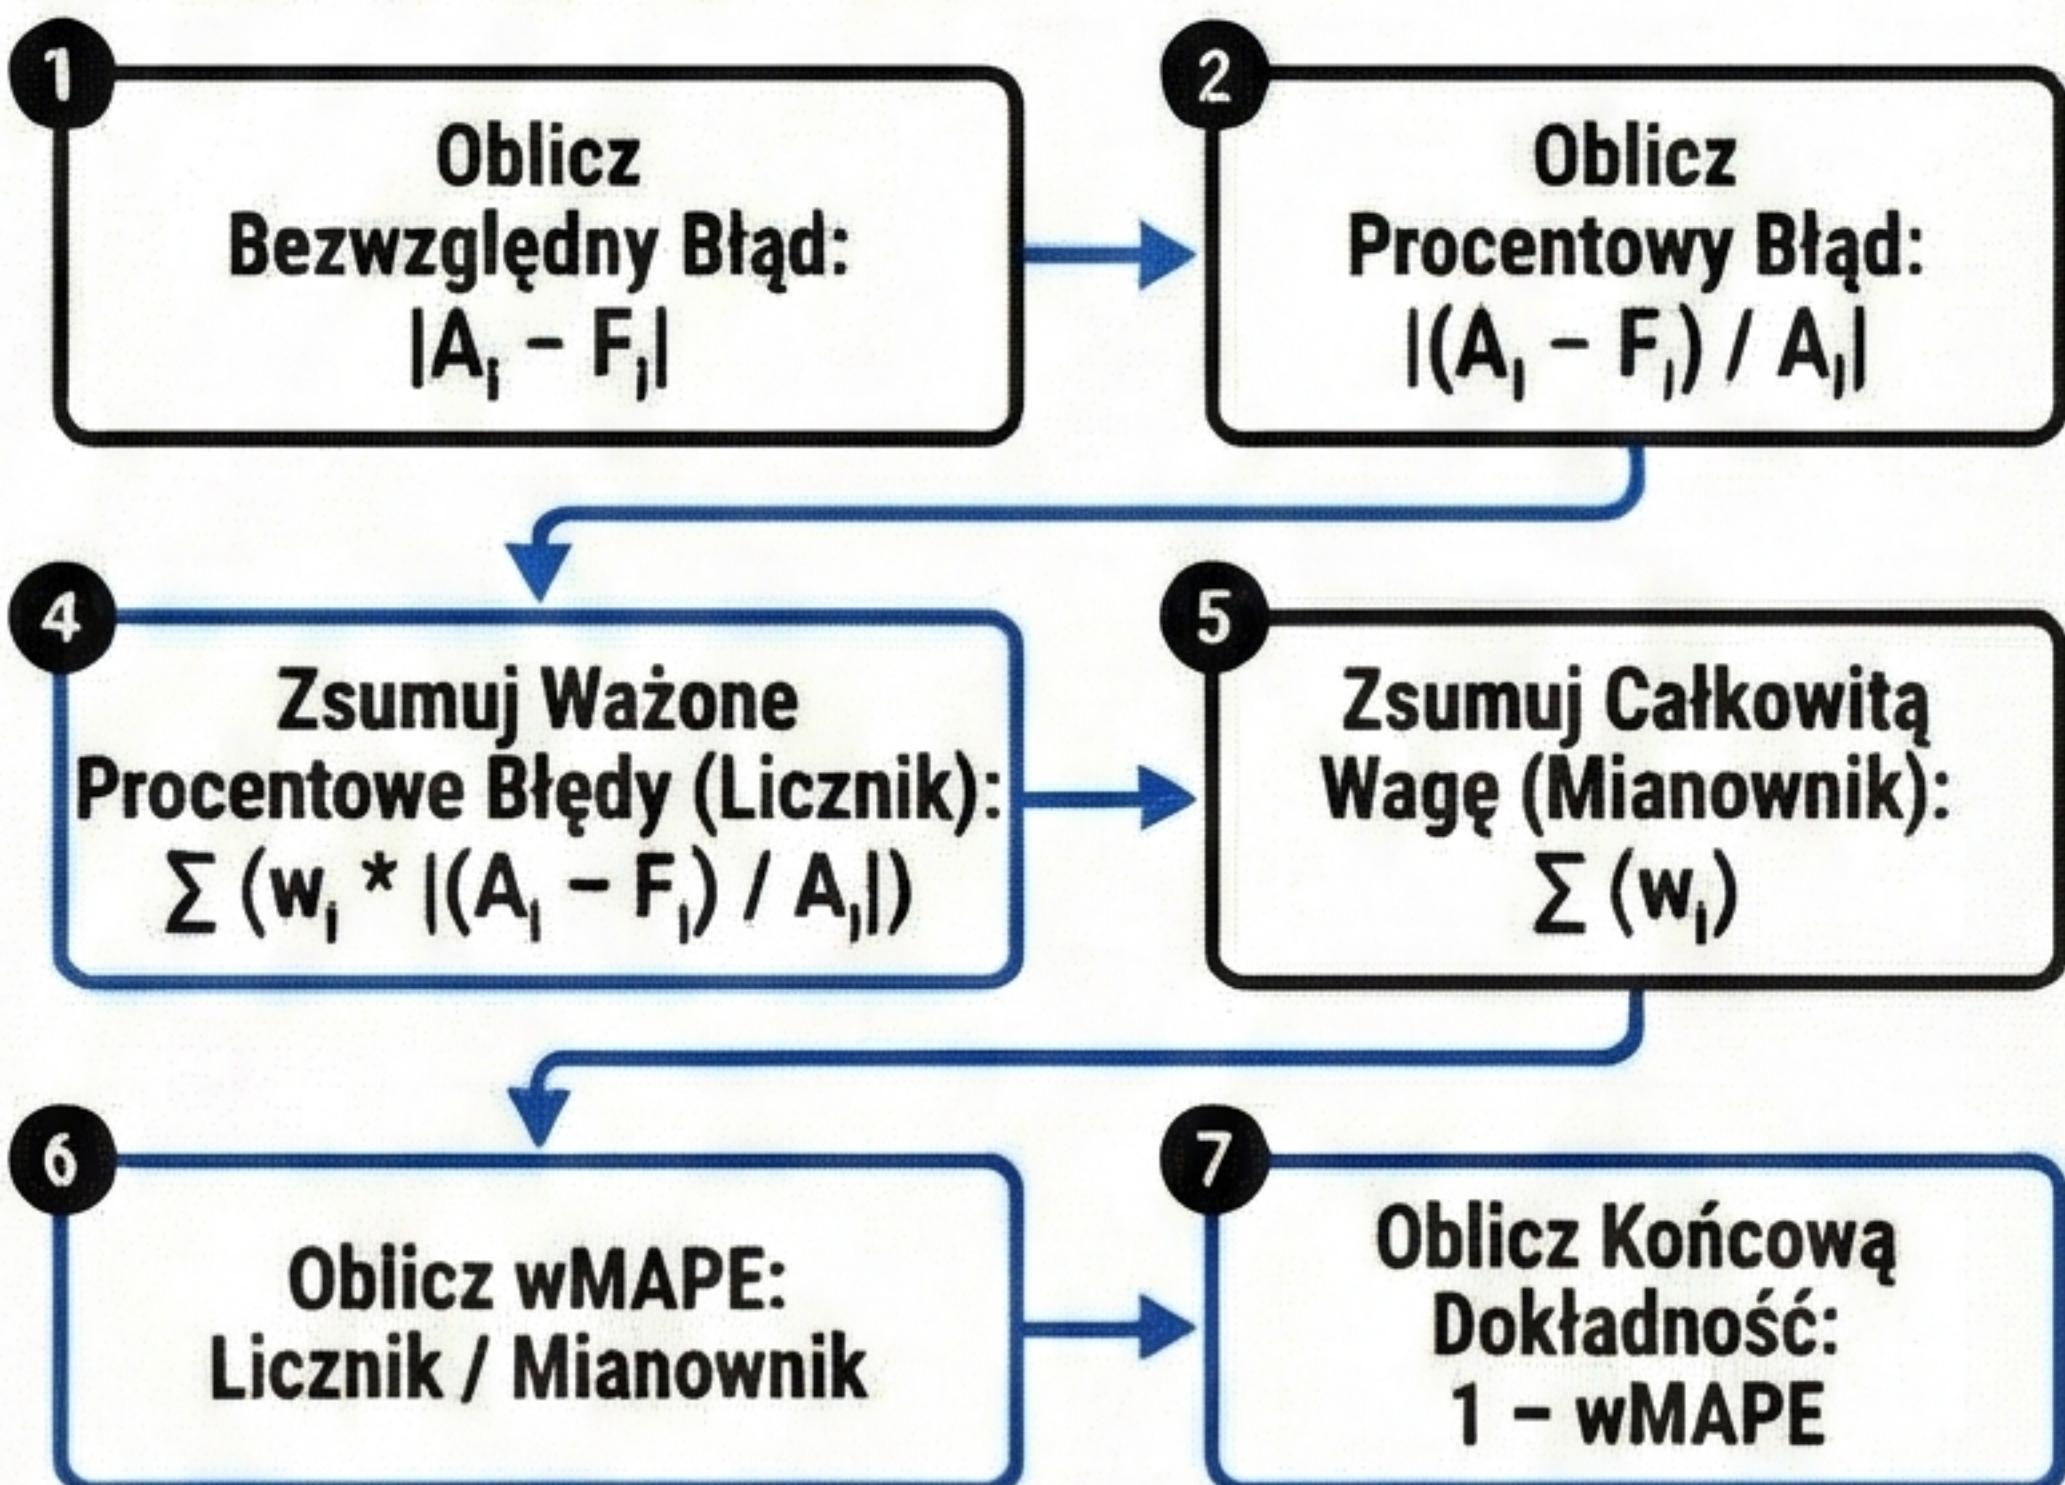
2. WZÓR I OBLCZENIA

$$1 - \text{wMAPE} = 1 - \frac{\sum (w_i * \left| \frac{A_i - F_i}{A_i} \right|)}{\sum (w_i)}$$

TERMS:

- A_i : Rzeczywisty popyt na element i
- F_i : Prognozowany popyt na element i
- w_i : Waga elementu i (np. COGS, Przychód)
- $\left| \frac{A_i - F_i}{A_i} \right|$: Bezwzględny Procentowy Błąd elementu i
- \sum : Sumowanie dla wszystkich elementów ($i=1$ do n)

CALCULATION STEPS:



3. PRZEPŁYW IMPLEMENTACJI POWER BI

