

Power BI: Modelowanie danych

Architektura wydajnych systemów analitycznych



dr Zbigniew Galar


Zmiana Paradygmatu: Z płaskiego arkusza do wielowymiarowego modelu

Płaski świat Excela

	A	B	C	D	E	F
1	Customer_ID					
2	A1	12345				
3	B2	12345	#N/A!			
4	A3	12345		VLOOKUP(...)		
5	A4	12345	VLOOKUP(...)		ERROR	
6	A5	12345				
7						
8			VLOOKUP(...)			
9				VLOOKUP(...)	ERROR	
10						Duplicate_Value
11						
12						
13						

- Wszystkie dane wymuszane w jednym arkuszu.
- Zależność od złożonych, obciążających pamięć funkcji WYSZUKAJ.PIONOWO.
- Ogromne, niewydajne pliki z powielającymi się wartościami.

Relacyjny model Power BI



- Logiczne łączenie rozproszonych grup danych bez ich fizycznego scalania.
- Tabele pozostają odrębne, połączone inteligentnymi relacjami.
- To właśnie modelowanie odpowiada za wydajność – zajmuje nawet 80% czasu pracy w Power BI.

Dwa Filary Modelu: Wymiary i Fakty



Tabela Faktów



Tabela Wymiarów

Zawartość

To, co się wydarzyło (np. transakcje, wizyty, produkcja).

Kto, co, gdzie (szczegółowy opis elementów z tabeli faktów).

Struktura

Bardzo długa (najwięcej wierszy w modelu). Zawiera głównie wartości numeryczne.

Bardzo szeroka (dużo kolumn tekstowych/alfanumerycznych). Jeden unikalny wiersz dla każdego elementu.

Klucze

Zawiera Klucze Obce (Foreign Keys) - wielokrotnie powtarzające się ID klientów, produktów.

Zawiera Klucz Główny (Primary Key) - unikalne ID.

Rola w wizualizacji

Dostarcza Wartości (Values), które są sumowane, liczone lub uśredniane.

Dostarcza Etykiet (Labels) na osiach, w wierszach i kolumnach wykresów.

Tkanka Łączna: Relacje to nie są zwykłe złączenia

W środowisku Power BI relacja nie polega na fizycznym łączeniu (JOIN) wierszy. Jej jedynym zadaniem jest przekazywanie filtrów z jednej tabeli do drugiej.

Strona '1': Tabela Wymiarów (zawsze po stronie 'jeden' z unikalnymi rekordami).




Strona '*': Tabela Faktów (po stronie 'wiele', gdzie rekordy się powtarzają).



Strzałka na linii: Kierunek, w którym przepływa filtr ograniczający widoczność danych.

Anatomia Przepływu Filtrów w Praktyce



Krok 1: Inicjacja

Wybór konkretnej Nazwy Produktu w tabeli Wymiaru (np. Product Name) zostaje przetłumaczony na jego unikalny ProductKey.

Krok 2: Transmisja

Wybrany ProductKey splywa rurociągiem relacji w kierunku wskazanym przez strzałkę (od Wymiaru do Faktów).




Krok 3: Filtrowanie

Tabela Sales (Fakty) natychmiast ukrywa wszystkie wiersze z wyjątkiem tych, które zawierają przekazany ProductKey. Wykresy aktualizują się błyskawicznie.

Anatomia Połączeń: Typy Kardynalności Relacji

Jeden-do-Wielu (1:N)



Standard branżowy. Stabilne połączenie Tabeli Wymiarów z Tabelą Faktów. Nie generuje dwuznaczności.


Wiele-do-Wiele (M:N)



[Ryzyko!] Brak unikalnych rekordów po obu stronach. Grozi podwójnym liczeniem lub pomijaniem danych w raportach.

Najlepsza praktyka: Cofnij się do Power Query i uprość tabele do postaci 1:N.


Jeden-do-Jeden (1:1)



Sygnal ostrzegawczy: Prawdopodobnie te dwie tabele powinny zostać scalone w jedną szeroką Tabelę Wymiarów w Power Query, aby uprościć model.


Kierunek Filtrowania: Bezpieczeństwo vs. Ryzyko

Filtrowanie Jednokierunkowe (Domyślne)




- Filtr płynie z Wymiaru (strona 1) do Faktów (strona *).
- Chroni model przed dwuznacznością wyników.
- Gwarantuje maksymalną wydajność silnika obliczeniowego.

Filtrowanie Dwukierunkowe (Bi-directional)




- Filtry przepływają w obie strony. Może wydawać się to wygodne.
- Krytyczne ryzyko: Wprowadza wieloznaczność, potencjalne błędne kalkulacje i drastycznie spowalnia odświeżanie raportu.
- Używaj wyłącznie, gdy jest to absolutnie konieczne.

Święty Graal Architektury: Schemat Gwiazdy



Star Schema to fizyczny ideał, do którego dążymy. Tabela Faktów spoczywa w wirtualnym centrum systemu. Wymiary otaczają ją jak planety, podłączone bezpośrednio. Ten kształt gwarantuje intuicyjność raportów i błyskawiczne działanie formuł DAX.

Złota zasada: Unikaj umieszczania wszystkich danych w jednej tabeli (syndrom Excela), ale nie rozbijaj ich też na nieskończoną ilość drobnych tabel (nadmierna normalizacja).



Patek Śniegu (Snowflake): Kompromis. Rozbicie szerokiego wymiaru do osobnych tabel. Akceptowalne, lecz nie optymalne.

Silnik VertiPaq: Tajemnica Pamięci i Kardynalności

Jak działa silnik? Power BI napędza VertiPaq. Pobiera i przechowuje dane pionowo (kolumnowo), a nie poziomo (wierszowo). Jego siła tkwi w potężnych algorytmach kompresji.


Kardynalność = liczba unikalnych wartości

Wysoka Kardynalność = Droga w utrzymaniu



Dużo unikalnych wartości (np. klucze główne, ID).
Silnik nie potrafi ich efektywnie skompresować.

Niska Kardynalność = Oszczędność Pamięci




Wiele powtarzających się wartości.
Algorytmy kompresji działają idealnie.

Głównym zadaniem architekta jest bezwzględna redukcja kardynalności tam, gdzie to możliwe.


Taktyki Optymalizacyjne: Anatomia Redukcji Kardynalności

1 Podział wartości złożonych

Przed




Nieskompresowana kolumna.




Rozbicie w Power Query (Każda nowa kolumna ma wielokrotnie niższe unikalne wartości bazowe).

2 Izolacja Czasu

Przed



Data + Precyzyjny Czas = Gigantyczna kardynalność.



Rozdziel lub całkowicie usuń czas, jeśli jest zbędny.



Optymalizacja Typów Danych

Klucze przechowuj jako Liczby Całkowite (Integers). Są one najłatwiejsze i najtańsze do kompresji dla silnika VertiPaq.

Kategoryzacja Danych: Nadawanie Semantycznego Kontekstu

Bariera Tekstowa:

Zarówno miasto 'Columbia' jak i kraj 'Columbia' są w modelu po prostu ciągiem znaków (Tekst). Power BI może błędnie je mapować na wizualizacjach geograficznych.

The screenshot illustrates the Power BI interface for categorizing data. The 'Column tools' ribbon is active, and the 'Data category' dropdown menu is open, showing options like 'Address', 'Place', 'City', 'County', 'State or Province', 'Postal code', 'Country', 'Continent', 'Latitude', 'Longitude', 'Web URL', and 'Image URL'. The 'City' option is highlighted. The background shows a table with columns like 'TotalOrderValue', 'LineTotal', 'Ciast', and 'City'. The 'Fields' pane on the right shows a list of fields, with 'City' selected under the 'Customers' category. A magnifying glass icon is placed over the 'City' field in the table.

Geografia

Przypisywanie kategorii Miasto, Kraj, Kod Pocztowy (wymaga pojawienia się ikony Globu przy polu).

Multimedia

Oznaczanie kolumn z adresami jako 'Image URL' – wizualizacja wygeneruje fizyczny obraz zamiast wyświetlać surowy link z bazy.

Wymiar Czasu: Pułapki Dat z Tabeli Faktów

Falszywa pokusa: Używanie dat bezpośrednio z Tabeli Faktów (np. Data Zamówienia) wydaje się proste, ale ostatecznie niszczy analitykę.



WEEKEND

ŚWIĘTO

1. Gubienie dni

Tabela faktów nie ma wierszy w dni, kiedy firma nie przyjmuje zamówień (weekendy, święta).

2. Luki w kalkulacji

Brak ciągłości uniemożliwia obliczanie różnicy czasu (np. między wysyłką a dostawą).

3. Lata fiskalne

Standardowe daty nie odzwierciedlają lat finansowych (np. zaczynających się w lipcu).


4. Awaria DAX

Wbudowane funkcje inteligencji czasowej (Time Intelligence) po prostu przestaną działać poprawnie.

Złoty Standard: Wymiar Dedykowanej Tabeli Dat

Niezbędne Kroki Konfiguracyjne



- 1. Ciągłość:** Tabela musi zawierać absolutnie każdą datę pomiędzy najwcześniejszym a najpóźniejszym wpisem w modelu.
- 2. Oznaczenie:** Konieczne jest użycie opcji Oznacz jako tabelę dat (pojawia się ikona karty identyfikacyjnej).
- 3. Sortowanie Moc:** Miesiące sortuj numerycznie po kolumnie typu 'RokMiesiąc' (np. 202101), nigdy alfabetycznie!



Select the **DateDim** table, and in the **Table Tools** menu, choose **Mark As Date Table**. Validate the column that contains one row for every date between the earliest and latest date in the model and has a date data type.

Eliminacja Tabel Widmo (Shadow Tables)


Power BI potajemnie tworzy mini-tabele w tle dla każdego pola daty, pożerając pamięć. Należy to wyłączyć na zawsze w **Opcjach globalnych**.



Obsługa Wielu Dat: Złożone Relacje Czasowe


Dylemat: Tabela faktów posiada Datę Zamówienia, Datę Wysyłki i Datę Dostawy. Pomiedzy dwiema tabelami może istnieć tylko jedna aktywna relacja.

Ścieżka 1: Relacje Nieaktywne (Zalecane)



- Ustaw relację główną jako aktywną.
- Dodaj relacje z pozostałymi datami (linie przerywane).
- Aktywuj je na żądanie bezpośrednio w miarach DAX (funkcja **USERELATIONSHIP**).

Ścieżka 2: Wymiary Wcieleniowe (Role-Playing)




- Zduplikuj tabelę Dat dla każdej roli.
- Utwórz aktywne relacje do każdej z nich.
- Ułatwia to wizualizację, ale drastycznie zwiększa rozmiar modelu (niezalecane przy ogromnych bazach).

DNA Perfekcyjnego Modelu: Złote Zasady Architekta Danych



1. Dąż do Schematu Gwiazdy

Wymiary z unikalnymi rekordami dostarczają etykiet (1). Fakty z transakcjami dostarczają wartości (*).



2. Chroń Przepływ Filtrów

Stosuj filtry jednokierunkowe. Unikaj relacji M:N i połączeń dwukierunkowych dla bezbłędności.



Optimum

3. Optymalizuj Kardynalność

Silnik VertiPaq nie znosi unikalnych tekstów. Rozbijaj kolumny, usuwaj czas z dat, używaj liczb całkowitych.



4. Szanuj Czas

Dedykowana, oznaczona Tabela Dat z ciągłością osi czasu to absolutny fundament inteligencji czasowej.

Reguła 80%: Modelowanie to 80% czasu pracy analityka.

Czysty i zoptymalizowany model sprawi, że raporty wizualne zbudują się same.